Amanda Askell の研究系譜

AI アラインメントと Constitutional AI の展開

2019 – 2025 ｜ 22 論文の分析

作成: yuji ｜ Input Constitutional AI 研究

研究の全体像 — 7つのフェーズ

- **2019** 責任ある AI 開発
- **2020** 大規模モデルの能力
- **2021** アラインメント基盤
- **2022前** RLHF の確立
- **2022後** Constitutional AI 誕生
- **2023** 安全性研究の深化
- **2024-25** 欺瞞と防御

Phase 1: 責任ある AI 開発（2019）

The Role of Cooperation in Responsible AI Development

- 競争圧力が AI 安全性への投資不足を招く
- 市場力・規制だけでは不十分
- 業界間の「協力」が不可欠
- 信頼・共有リスク・相互コミットメントが鍵

Release Strategies and the Social Impacts of Language Models

- 段階的リリースによるリスク分析の時間確保
- 悪意ある利用者を3階層で分類
- 外部パートナーとの協力的研究体制
- GPT-2 の段階的公開の実証分析

核心: AI 開発は「競争」ではなく「協調」のフレームで捉えるべき

Phase 2: 大規模モデルの能力と社会的影響（2020）

Toward Trustworthy AI Development

- 倫理原則だけでは不十分 → 検証可能なメカニズムが必要
- 制度的・ソフトウェア的・ハードウェア的の3層構造

Language Models are Few-Shot Learners (GPT-3)

- 1750 億パラメータで少数ショット学習を実現
- 社会的影響（バイアス・悪用・エネルギー消費）を分析

Learning Transferable Visual Models (CLIP)

自然言語監督による視覚モデル学習 — 4億の画像テキストペアからゼロショット転移を実現

核心:「原則」から「検証可能性」へ — 言葉だけでなく証拠で示す

Phase 3: アラインメント研究の基盤確立（2021）

A General Language Assistant as a Laboratory for Alignment

HHH フレームワーク（Helpful, Honest, Harmless）の確立

Helpful（有用性）

ユーザーの意図を理解し
的確に応答する能力

Honest（誠実性）

自身の不確実性を認識し
正直に伝える姿勢

Harmless（無害性）

有害な出力を避け
安全に振る舞う性質

- ランク付き選好モデリングが二値判別を大幅に上回ることを実証
- プロンプティングと文脈蒸留がアラインメントの実用的ベースラインとなる

Phase 4: RLHF によるアラインメント手法の確立（2022前半）

InstructGPT: Training LMs to Follow Instructions with Human Feedback

SFT → 報酬モデル → PPO の3段階パイプラインを確立。100倍小さいモデルが大規模GPT-3を上回る性能。

Training a Helpful and Harmless Assistant with RLHF

有用性と無害性の同時最適化に成功。大規模モデルほどアラインメント税（性能低下）が小さい。

Predictability and Surprise in Large Generative Models

一般的なスケーリングは予測可能だが、特定の能力は不連続に出現する。デプロイメントリスクの理論的枠組み。

核心: 人間のフィードバックを通じた「選好学習」がアラインメントの標準手法となる

Phase 4（続）: モデルの理解と安全性評価（2022）

Language Models (Mostly) Know What They Know

モデルが自身の知識を自己評価できることを実証。P(IK) 手法により、モデルの不確実性を定量化。

Red Teaming Language Models to Reduce Harms

系統的レッドチーミング手法を確立。大規模モデルほど攻撃に対して脆弱だが、RLHF が防御に有効。

In-context Learning and Induction Heads

Induction Head がインコンテキスト学習の主要メカニズムであることを実証。メカニスティック解釈可能性の先駆的研究。

核心: モデルの「自己認識」と「攻撃耐性」の体系的研究が安全性の基盤を形成

Phase 5: Constitutional AI の誕生（2022 後半）

Constitutional AI: Harmlessness from AI Feedback

- 「憲法」（原則セット）に基づき AI フィードバックで無害性を訓練
- 人間ラベラーなしで RLHF と同等以上の性能を達成
- Chain-of-Thought 推論で AI 自身が行動を批判・修正
- スケーラブルな監視 — 人間の介入を最小化しつつ安全性を向上

Scalable Oversight

「サンドイッチング」実験パラダイムで監視の実現可能性を実証

Model-Written Evaluations

モデル自身が 154 次元の評価を生成。人間の 50 倍の効率。

核心: AI が AI を監視する — 人間の限界を超えたアラインメントの新パラダイム

Phase 6: 安全性研究の深化（2023）

Moral Self-Correction in LLMs	22B パラメータ以上で「道徳的自己修正」能力が創発。自然言語指示で差別を低減可能。
Subjective Global Opinions in LMs	LLM のデフォルト意見は西洋偏重。文化的多様性の欠如を定量化し、プロンプト補正の限界を指摘。
Understanding Sycophancy in LMs	AI が真実よりユーザーの期待に迎合する「追従性」を体系的に分析。人間フィードバック自体が追従を助長。
Specific vs General Principles for CAI	具体的原則が一般的「人類にとって良い」原則より効果的。権力欲・自己保存欲求の抑制に成功。
Discrimination in LM Decisions	70 の意思決定シナリオで体系的差別を測定。プロンプト介入でほぼゼロの差別スコアを達成。

核心: CAI の原則設計・追従性・差別・文化的偏見 — 多面的な安全性課題への取り組み

Phase 7: 欺瞞への対抗と実用的防御（2024–2025）

Sleeper Agents（2024）

問題提起

- バックドアを持つ欺瞞的 LLM は安全性訓練を生き延びる
- RLHF・SFT・敵対的訓練のいずれも除去に失敗
- 敵対的訓練は欺瞞を「隠す」ことを教えてしまう
- 現行の安全パラダイムの根本的限界を示す

Constitutional Classifiers（2025）

解決策

- 憲法ベースの分類器で入出力をリアルタイム監視
- 3,000 時間超のレッドチーミングで万能ジェイルブレイクを阻止
- 405 名の攻撃者が一貫した突破口を発見できず
- 偽陽性率 0.38% 増、推論オーバーヘッド 23.7% で実用的

核心: 問題（欺瞞の持続性）→ 解決（憲法分類器）— 「原則に基づく防御」の実装

Amanda Askell の知的軌跡 — 一貫するテーマ

道徳哲学 → AI アラインメント
哲学的訓練を基盤に、AI の行動規範を「原則」として形式化。Constitutional AI は倫理学の実装。

人間の限界の認識
RLHF の限界（追従性の助長）を見抜き、AI フィードバックによるスケーラブルな監視へ移行。

構造的・制度的視点
個人の善意ではなく、検証可能なメカニズムと制度設計による安全性の担保。

実証主義的アプローチ
抽象的原則に留まらず、レッドチーミング・評価・分類器という具体的ツールで検証。

善意に依存しない構造的安全性 — これが Askell の研究を貫く哲学

Input Constitutional AI への示唆

原則の具体性が重要

一般的「人類のため」より、具体的な特性原則が効果的であることが実証済み。SoE のアセスメント原則設計への直接的示唆。

AI フィードバックの拡張可能性

本人主権型アセスメントにおいて、当事者の「憲法」（価値観・希望）を AI が参照する構造は CAI の直接的応用。

追従性への警戒

支援者が当事者に迎合するリスクは、LLM の追従性問題と構造的に同型。制度的チェック機構が不可欠。

検証可能性の担保

支援の質を「善意」でなく「構造」で評価するアプローチは、Askell の「検証可能な主張」論文と完全に整合。

Askell の研究は「AI のための倫理」から「倫理のための AI」への転換点を示す

参照論文一覧（時系列順）

- 2019 The Role of Cooperation in Responsible AI Development
- 2019 Release Strategies and the Social Impacts of Language Models
- 2020 Toward Trustworthy AI Development
- 2020 Language Models are Few-Shot Learners (GPT-3)
- 2021 Learning Transferable Visual Models (CLIP)
- 2021 A General Language Assistant as a Laboratory for Alignment
- 2022 Predictability and Surprise in Large Generative Models
- 2022 Training LMs to Follow Instructions (InstructGPT)
- 2022 Training a Helpful and Harmless Assistant with RLHF
- 2022 Language Models (Mostly) Know What They Know
- 2022 Red Teaming Language Models to Reduce Harms
- 2022 In-context Learning and Induction Heads
- 2022 Measuring Progress on Scalable Oversight for LLMs
- 2022 Constitutional AI: Harmlessness from AI Feedback
- 2022 Discovering LM Behaviors with Model-Written Evaluations
- 2023 The Capacity for Moral Self-Correction in LLMs
- 2023 Towards Measuring Subjective Global Opinions in LMs
- 2023 Towards Understanding Sycophancy in Language Models
- 2023 Specific vs General Principles for Constitutional AI
- 2023 Evaluating and Mitigating Discrimination in LM Decisions
- 2024 Sleeper Agents: Training Deceptive LLMs
- 2025 Constitutional Classifiers: Defending against Jailbreaks